

## LISTA 0

1. a) Para  $i = 1, \dots, n$ , temos que

$$f_{X_i}(x_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}(x_i - \mu)^2\right]$$

Por ser uma amostra aleatória, as variáveis aleatórias são independentes. Logo, a densidade conjunta da amostra é dada por

$$\begin{aligned} f_X(x) &= \prod_{i=1}^n f_{X_i}(x_i) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}(x_i - \mu)^2\right] \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right] \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2)\right] \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\sum_{i=1}^n \frac{x_i^2}{2\sigma^2} + 2\mu \sum_{i=1}^n \frac{x_i}{2\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right] \\ &= \frac{\exp[-n\mu^2/2\sigma^2]}{(2\pi\sigma^2)^{n/2}} \exp\left[-\sum_{i=1}^n \frac{x_i^2}{2\sigma^2} + \mu \sum_{i=1}^n \frac{x_i}{\sigma^2}\right] \end{aligned}$$

Se definirmos  $a(\theta) = \frac{\exp[-n\mu^2/2\sigma^2]}{(2\pi\sigma^2)^{n/2}}$ ,

$b(x) = 1$ ,  $c_1(\theta) = -\frac{1}{2\sigma^2}$ ,  $c_2(\theta) = \frac{\mu}{\sigma^2}$ ,

$d_1(x) = \sum_{i=1}^n x_i^2$  e  $d_2(x) = \sum_{i=1}^n x_i$ , então

$$f_X(x) = a(\theta) b(x) \exp\left[\sum_{i=1}^2 c_i(\theta) d_i(x)\right]$$

b) Vamos usar o Teorema da Fatoração para resolver esse problema

Teorema da Fatoração: Seja  $f_X(x|\theta)$  a função densidade de probabilidade ou função de probabilidade conjunta de uma amostra  $X$ . Uma estatística  $T(X)$  é suficiente para  $\theta$  se, e somente se, existem funções  $g(t|\theta)$  e  $h(x)$  tais que, para qualquer ponto amostral  $x$  e  $\theta$  no espaço paramétrico, vale a igualdade

$$f_X(x|\theta) = g(T(x)|\theta) h(x)$$

Voltando ao resultado do item a), temos a forma

$$f_X(x|\theta) = \frac{\exp[-n\mu^2/2\sigma^2]}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i\right]$$



Se fizermos  $c(\theta) = \left( -\frac{1}{2\sigma^2}, \frac{\mu}{\sigma^2} \right)'$  e

$$T(X) = \left( \sum_{i=1}^n X_i^2, \sum_{i=1}^n X_i \right), \text{ então}$$

$$f_X(x|\theta) = g(T(x)|\theta)h(x),$$

$$\text{onde } g(T(X)|\theta) = \frac{\exp[-n\mu^2/2\sigma^2]}{(2\pi\sigma^2)^{n/2}} \exp[T(x)c(\theta)]$$

$$\text{e } h(x) = 1.$$

Logo,  $T(X) = \left( \sum_{i=1}^n X_i^2, \sum_{i=1}^n X_i \right)$  é uma estatística suficiente para  $\theta = (\mu, \sigma^2)$

$$c) \text{ Seja } L(\theta|x) = \prod_{i=1}^n f_{X_i}(x_i)$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right] \text{ a função de}$$

verossimilhança. O objetivo é maximizar  $L(\theta|x)$  com relação a  $\theta = (\mu, \sigma^2)$ .

Isso é equivalente a encontrar os pontos  $\theta = (\mu, \sigma^2)$  que maximizam  $l(\theta|x) = \log(L(\theta|x))$ .

$$l(\theta|x) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{n}{2} \log(\sigma^2)$$

$$- \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

- Encontrando o ponto em relação a  $\mu$

Derivamos  $l(\theta|x)$  em relação a  $\mu$  e igualamos a 0 para encontrar o ponto  $\mu$

$$\frac{\partial l(\theta|x)}{\partial \mu} = \frac{2}{2\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$$

$$\Rightarrow \sum_{i=1}^n (x_i - \mu) = 0$$

$$\Rightarrow \sum_{i=1}^n x_i - n\mu = 0$$

$$\Rightarrow \mu = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$$

e o ponto é dado por  $\hat{\mu} = \bar{x}$ .

- Encontrando o ponto em relação a  $\sigma^2$

Derivamos  $l(\theta|x)$  em relação a  $\sigma^2$  e igualamos a 0 para encontrar o ponto  $\sigma^2$

$$\frac{\partial l(\theta|x)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

$$\Rightarrow -n\sigma^2 + \sum_{i=1}^n (x_i - \mu)^2 = 0$$

$$\Rightarrow n\sigma^2 = \sum_{i=1}^n (x_i - \mu)^2$$

$$\Rightarrow \sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$



Substituindo o ponto que encontramos para  $\mu$ , temos que  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ .

Portanto, os estimadores de máxima verossimilhança de  $\theta = (\mu, \sigma^2)$  são  $\hat{\theta} = (\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2)$ .

d) Consideremos a estatística

$$T = \frac{\bar{x} - \mu}{S/\sqrt{n}},$$

$$\text{onde } S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

Inicialmente, dividamos o numerador e denominador pelo desvio padrão  $\sigma$  da população, e teremos

$$T = \frac{\sqrt{n}(\bar{x} - \mu)/\sigma}{S/\sigma}$$

O numerador  $Z = \sqrt{n}(\bar{x} - \mu)/\sigma$  tem distribuição  $N(0, 1)$ . O quadrado do denominador pode ser escrito como

$$\frac{S^2}{\sigma^2} = \frac{n-1}{n-1} \cdot \frac{S^2}{\sigma^2} = \frac{Y}{n-1},$$

onde  $Y = (n-1)S^2/\sigma^2$ . Como os  $X_i$  são normais,  $Y$  tem distribuição  $\chi^2(n-1)$ . Logo,  $T$  é o quociente entre uma v. a.  $N(0, 1)$  e a raiz quadrada de uma v. a.  $\chi^2(n-1)$ , dividida pelo número de graus de liberdade.

Se  $Z$  é uma v.a.  $N(0,1)$  e  $Y$  uma v.a.  $\chi^2(v)$ , com  $Z$  e  $Y$  independentes, então

$$t = \frac{Z}{\sqrt{Y/v}} \sim t(v)$$

Usando esse resultado, temos que

$$T = \frac{(\bar{X} - \mu)}{S/\sqrt{n}} = \frac{Z}{\sqrt{Y/(n-1)}} \sim t(n-1)$$

Observe que  $Z$  e  $Y$  são independentes, pois  $\bar{X}$  e  $S^2$  são independentes.

Sob  $H_0$ ,  $\mu_0$  é tido como o verdadeiro valor de  $\mu$ , e a estatística ~~test~~ é dada por

$$T = \frac{(\bar{X} - \mu_0)}{S/\sqrt{n}}, \text{ que sabemos agora ter uma}$$

distribuição  $t$  de Student com  $(n-1)$  graus de liberdade.

Sob  $H_1$ , considerando  $\mu \neq \mu_0$ , a estatística

$$T = \frac{(\bar{X} - \mu)}{S/\sqrt{n}} \text{ também segue uma distribuição}$$

$t$  de Student com  $(n-1)$  graus de liberdade.



estamos, agora, em condições de testar as hipóteses

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0$$

A estatística a ser usada, como visto anteriormente, é

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}$$

Fixado o nível de significância  $\alpha$ , podemos encontrar o valor  $t_c$  tal que  $P(|T| < t_c) = 1 - \alpha$

Colhida a amostra de  $n$  indivíduos, calculamos os valores  $\bar{x}_0$  e  $s_0^2$  das estatísticas  $\bar{X}$  e  $S^2$ , respectivamente, e depois o valor  $t_0 = \sqrt{n}(\bar{x}_0 - \mu_0)/s_0$  de  $T$ . Se o valor dessa estatística for inferior a  $-t_c$ , ou superior a  $t_c$ , rejeita-se  $H_0$ . Caso contrário, aceita-se  $H_0$ .

Logo, a região crítica é dada por

$$R_c = \{t_0 \in \mathbb{R} \mid t_0 < -t_c \text{ ou } t_0 > t_c\}$$

e a região de aceitação é a região complementar à região crítica

$$R_A = \{t_0 \in \mathbb{R} \mid -t_c \leq t_0 \leq t_c\}$$

A função poder do teste é dada por

$$\pi(\mu) = 1 - P(\text{erro tipo II})$$

$$= 1 - P(\text{não rejeitar } H_0 \mid H_0 \text{ é falsa})$$

$$= 1 - P(|T| < t_c),$$

$$\text{Onde } T = \frac{\bar{X} - \mu}{S/\sqrt{n}}, \quad \mu \neq \mu_0 \text{ e } t_c \text{ é o valor}$$

definido anteriormente.



e) Um teste de razão de verossimilhança (TRV) é qualquer teste que tem a região de rejeição da forma  $\{x : \lambda(x) \leq c\}$ , onde  $c$  é qualquer número satisfazendo  $0 \leq c \leq 1$ .

$$\text{Aqui, } \lambda(x) = \Lambda = \frac{L(\hat{\theta}_0)}{L(\hat{\theta})}$$

é a estatística do TRV.

• Calculando  $L(\hat{\theta}_0)$

Sob  $H_0$ ,  $\theta_0 = (\mu_0, \sigma^2)$ . Com isso,  $L(\theta)$  é maximizada apenas em  $\sigma^2$ , pois  $\mu_0$  é conhecido. Do item c), vimos que o valor  $\sigma^2$  que maximiza  $L(\theta)$  é

$$\hat{\sigma}_0^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n},$$

onde, nesse caso,  $\mu$  é substituído por  $\mu_0$ .

Logo,  $\hat{\theta}_0 = (\mu_0, \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2)$ , e

$$L(\hat{\theta}_0) = \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp \left[ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_0)^2 \right]$$

$$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp \left[ -\frac{n}{2\sigma_0^2} \sigma_0^2 \right]$$

$$= \frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp [-n/2]$$

• Calculando  $L(\hat{\theta})$

Como não temos restrições em relação aos valores de  $\mu$  e  $\sigma^2$ , do item c), sabemos que  $L(\theta)$  é maximizada em

$$\hat{\mu} = \bar{x} \quad \text{e} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Logo,  $\hat{\theta} = (\bar{x}, \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2)$ , e

$$L(\hat{\theta}) = \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp\left[-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \bar{x})^2\right]$$

$$= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp\left[-\frac{n}{2\hat{\sigma}^2} \hat{\sigma}^2\right]$$

$$= \frac{1}{(2\pi\hat{\sigma}^2)^{n/2}} \exp[-n/2]$$

Uma vez que ~~que~~ calculamos  $L(\hat{\theta}_0)$  e  $L(\hat{\theta})$ , temos que

$$\Lambda = \frac{(2\pi\sigma_0^2)^{-n/2} \exp[-n/2]}{(2\pi\hat{\sigma}^2)^{n/2} \exp[-n/2]}$$

$$= (\hat{\sigma} / \sigma_0)^{n/2}$$

$$= \left[ \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \mu_0)^2} \right]^{n/2}$$



Logo, rejeitamos  $H_0$  se

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \mu_0)} < C$$

~~Para o teste de hipóteses  $H_0$~~

Seja  $X_1, \dots, X_n$  uma amostra aleatória de  $X$ , com função de máxima verossimilhança  $L(\theta)$ .

Seja  $r_0$  o número de parâmetros livres sob a hipótese nula  $H_0: \theta \in \Theta_0$ , e  $r$  o número de parâmetros livres especificado por  $\theta \in \Theta$ , onde  $\Theta$  é o espaço paramétrico de  $\theta$ . Então, a distribuição da estatística  $-2 \log \Lambda$  converge para uma distribuição qui-quadrada conforme o tamanho amostral  $n \rightarrow \infty$ . O número de graus de liberdade da distribuição limite é  $r - r_0$ .

Neste exercício, a hipótese nula especifica  $\mu = \mu_0$ , mas não especifica  $\sigma^2$ , então há um parâmetro livre,  $r_0 = 1$ . Para  $\theta \in \Theta$ ,  $\mu$  e  $\sigma^2$  não são especificados, então há dois parâmetros livres,  $r = 2$ . Logo, sob  $H_0$ , conforme  $n \rightarrow \infty$

$$-2 \log \Lambda \rightarrow \chi^2_1 \text{ em distribuição}$$

2. a) Seja  $Q = \sum_{i=1}^n (Y_i - \beta_1 X_{i1} - \dots - \beta_K X_{iK})^2$

Para encontrar o estimador de mínimos quadrados de  $\beta$ , fazemos a derivada parcial de  $Q$  em relação a cada elemento de  $\beta$  e igualamos a zero. Em seguida, resolvemos a equação resultante para os valores de  $\beta$ , e os valores encontrados é o estimador de mínimos quadrados.

Dessa forma, dá muito trabalho resolver. Vamos deixar  $Q$  na forma matricial para facilitar os cálculos.

$$\begin{aligned} Q &= (Y - X\beta)'(Y - X\beta) \\ &= (Y' - (X\beta)')(Y - X\beta) \\ &= Y'Y - (X\beta)'Y - Y'X\beta + (X\beta)'(X\beta) \end{aligned}$$

Como  $(X\beta)'Y$  é um número, então  $(X\beta)'Y = ((X\beta)'Y)' = Y'X\beta$ , logo

$$Q = Y'Y - 2Y'X\beta + \beta^t X^t X \beta$$

Se  $x$  é um vetor e  $A$  uma matriz de constantes, então

$$\frac{\partial x^t A x}{\partial x} = x'(A + A') ;$$

$$\frac{\partial A x}{\partial x} = A$$



Encontramos o estimador de mínimos quadrados fazendo  $\frac{\partial Q}{\partial \beta} = 0$  e encontrando o ponto  $\hat{\beta}$  que satisfaz essa igualdade.

$$\frac{\partial Q}{\partial \beta} = \frac{\partial}{\partial \beta} (Y'Y - 2Y'X\beta + \beta'X'X\beta)$$

$$= -2 \frac{\partial Y'X\beta}{\partial \beta} + \frac{\partial \beta'X'X\beta}{\partial \beta}$$

$$= -2Y'X + \beta'(X'X + (X'X)')$$

$$= -2Y'X + \beta'(X'X + X'X)$$

$$= -2Y'X \quad 2\beta'X'X = 0$$

$$\Rightarrow \beta'X'X = Y'X \Rightarrow (\beta'X'X)' = (Y'X)'$$

$$\Rightarrow X'X\beta = X'Y \Rightarrow \beta = (X'X)^{-1}X'Y$$

$$\text{Portanto, } \hat{\beta} = (X'X)^{-1}X'Y$$

6) Seja  $X_i$  a  $i$ -ésima linha da matriz  $X$ .

Então,  $Y_i = X_i\beta + \varepsilon_i$ . Como  $\varepsilon_i \sim N(0, \sigma^2)$ ,

$$Y_i \sim N(X_i\beta, \sigma^2).$$

Logo,  $Y$  é um vetor de variáveis aleatórias normais

$$\text{Fazendo } E(Y) = E(X\beta + \varepsilon) = X\beta \text{ e}$$

$$\text{Var}(Y) = \text{Var}(X\beta + \varepsilon) = \text{Var}(\varepsilon) = \sigma^2 I,$$

Temos que  $Y \sim N(X\beta, \sigma^2 I)$ .

Como  $\hat{\beta} = (X'X)^{-1}X'Y$ , os componentes de  $\hat{\beta}$  são ~~as~~ combinações lineares dos elementos de  $Y$ . Como cada elemento de  $Y$  segue uma distribuição, então os componentes de  $\hat{\beta}$  também seguem uma distribuição normal.

$$\text{Logo, } \hat{\beta} \sim N(E(\hat{\beta}), \text{Var}(\hat{\beta})).$$

Se  $A$  é uma matriz de constantes e  $W$  um vetor de variáveis aleatórias, então

$$\begin{aligned} E(AW) &= A E(W) \\ \text{Var}(AW) &= A \text{Var}(W) A' \end{aligned}$$

Com isso,

$$\begin{aligned} E(\hat{\beta}) &= E((X'X)^{-1}X'Y) = (X'X)^{-1}X'E(Y) \\ &= (X'X)^{-1}X'X\beta = \beta \end{aligned}$$

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \text{Var}((X'X)^{-1}X'Y) \\ &= (X'X)^{-1}X' \text{Var}(Y) (X'X)^{-1}X' \\ &= (X'X)^{-1}X' \sigma^2 I X (X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1}X'X (X'X)^{-1} \\ &= \sigma^2 (X'X)^{-1} \end{aligned}$$

Portanto,

$$\hat{\beta} \sim N(\beta, \sigma^2 (X'X)^{-1})$$



c) Uma vez que  $\hat{\beta} \sim N(\beta, \sigma^2 (X'X)^{-1})$ , sabemos que para cada componente  $k$  de  $\hat{\beta}$ ,

$$\hat{\beta}_k \sim N(\beta_k, \sigma^2 S_{kk}),$$

onde  $S_{kk}$  é o  $k$ -ésimo elemento da diagonal de  $(X'X)^{-1}$ . Logo,

$$Z_k = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2 S_{kk}}} \sim N(0, 1)$$

Vamos usar o seguinte Teorema:

Se  $x \sim N(0, I)$  e  $A$  é uma matriz simétrica ( $A' = A$ ) e idempotente ( $AA = A$ ), então  $x'Ax$  segue uma distribuição  $\chi^2_v$ , onde  $v$  é o posto de  $A$ .

Seja  $\hat{\varepsilon} = Y - X\hat{\beta}$  o vetor de resíduos, logo

$$\begin{aligned}\hat{\varepsilon} &= Y - X(X'X)^{-1}X'Y = (I - X(X'X)^{-1}X')Y \\ &= MY,\end{aligned}$$

onde  $M = I - X(X'X)^{-1}X'$ .

Temos que

$$\begin{aligned} M' &= (I - X(X'X)^{-1}X')' = I' - (X(X'X)^{-1}X')' \\ &= I - (X')'(X(X'X)^{-1})' = I - X((X'X)^{-1})'X' \\ &= I - X((X'X)')^{-1}X' = I - X(X'X)^{-1}X' = M \end{aligned}$$

e

$$\begin{aligned} MM &= (I - X(X'X)^{-1}X')(I - X(X'X)^{-1}X') \\ &= II - X(X'X)^{-1}X'I - IX(X'X)^{-1}X' \\ &\quad + (X(X'X)^{-1}X')(X(X'X)^{-1}X') \\ &= I - 2X(X'X)^{-1}X' + \underbrace{X(X'X)^{-1}X'X(X'X)^{-1}X'}_I \\ &= I - 2X(X'X)^{-1}X' + X(X'X)^{-1}X' \\ &= I - X(X'X)^{-1}X = M \end{aligned}$$

Logo,  $M$  é simétrica e idempotente

Seja  $S^2 = \frac{\hat{\varepsilon}'\varepsilon}{n-p}$  um estimador para  $\sigma^2$

↳ aqui é  $K$  ao invés de  $p$



Precisamos, agora, de alguns resultados de matrizes:

- O ~~rank~~ posto de uma matriz idempotente é o seu traço.

- $\text{Tr}(A+B) = \text{Tr}(A) + \text{Tr}(B)$

- $\text{Tr}(AB) = \text{Tr}(BA)$ , onde  $A$  é  $m \times n$  e  $B$   $n \times m$

então,

$$\text{posto}(M) = \text{Tr}(M)$$

$$= \text{Tr}(I - X(X'X)^{-1}X')$$

$$= \text{Tr}(I) - \text{Tr}(X(X'X)^{-1}X')$$

$$= \text{Tr}(I) - \text{Tr}(X'X(X'X)^{-1})$$

$$= \text{Tr}(I) - \text{Tr}(I) = n - K$$

$$\downarrow$$
$$n \times n$$

$$\downarrow$$
$$K \times K$$

com isso,

$$V = \frac{(n-K)S^2}{\sigma^2} = \frac{\sum \hat{\varepsilon}_i^2}{\sigma^2}$$

Temos que

$$\begin{aligned}MX &= (I - X(X'X)^{-1}X')X \\ &= X - X \underbrace{(X'X)^{-1}X'X}_I = X - X = 0\end{aligned}$$

a partir disso,

$$\hat{\varepsilon} = MY = M(X\beta + \varepsilon) = MX\beta + M\varepsilon = M\varepsilon$$

$$\begin{aligned}e \quad V &= \frac{\hat{\varepsilon}'\varepsilon}{\sigma^2} = \frac{(M\varepsilon)'M\varepsilon}{\sigma^2} = \frac{\varepsilon' M' M \varepsilon}{\sigma^2} \\ &= \frac{\varepsilon' M M \varepsilon}{\sigma^2} = \left(\frac{\varepsilon}{\sigma}\right)' M \left(\frac{\varepsilon}{\sigma}\right)\end{aligned}$$

Como  $\varepsilon/\sigma \sim N(0, I)$ , aplicando o Teorema mencionado, sabemos que  $V \sim \chi^2_{n-k}$

Se  $Z_k$  e  $V$  são duas variáveis aleatórias independentes, pelo resultado descrito em 1. d),

$$T = \frac{Z_k}{\sqrt{V/(n-k)}} \sim t_{n-k}$$